POLITECHNIKA RZESZOWSKA
im. Ignacego Łukasiewicza
WYDZIAŁ MATEMATYKI I FIZYKI STOSOWANEJ

Krzysztof Koza

PROJEKT Z STATYSTYCZNEJ ANALIZY DANYCH

Rzeszów 2025

Spis treści

1.Opis użytych danych.....3
2. Wyznaczenie podstawowych parametrów opisowych.....4
3. Graficzna reprezentacja danych.....7
4. Weryfikacja hipotez statystycznych.....12
5.Listing komend generujących wyniki.....14
6. Opis użytych funkcji środowiska R.....15

1.Opis użytych danych

Dane wykorzystane w projekcie pochodzą z serwisu Kaggle https://www.kaggle.com/code/arezoodahesh/hourly-energy-consumption-with-prophet/notebook

Zbiór danych zawiera informacje dotyczące godzinowego zużycia energii elektrycznej w różnych regionach Stanów Zjednoczonych. Celem danych jest umożliwienie analizy trendów, sezonowości oraz prognozowania zapotrzebowania na energię.

Źródłem danych jest PJM Interconnection – organizacja zajmująca się zarządzaniem siecią energetyczną i rynkiem energii w USA. Dane obejmują pomiary godzinowe z kilku lat dla poszczególnych obszarów , co pozwala na przeprowadzenie zarówno analizy czasowej, jak i porównawczej pomiędzy regionami.

Zbiór danych został wybrany ze względu na jego:

- kompletność (brak dużych luk w danych),
- regularność (pomiar co godzinę),
- praktyczne zastosowanie (planowanie i optymalizacja zużycia energii),
- możliwość przeprowadzenia pełnej analizy statystycznej i prognozowania.

	Datetime	AEP_MW
1	2004-12-31 01:00:00	13478
2	2004-12-31 02:00:00	12865
3	2004-12-31 03:00:00	12577
4	2004-12-31 04:00:00	12517
5	2004-12-31 05:00:00	12670
6	2004-12-31 06:00:00	13038
7	2004-12-31 07:00:00	13692
8	2004-12-31 08:00:00	14297
9	2004-12-31 09:00:00	14719
10	2004-12-31 10:00:00	14941
11	2004-12-31 11:00:00	15184
12	2004-12-31 12:00:00	15009
13	2004-12-31 13:00:00	14808
14	2004-12-31 14:00:00	14522
15	2004-12-31 15:00:00	14349
16	2004-12-31 16:00:00	14107
17	2004-12-31 17:00:00	14410
18	2004-12-31 18:00:00	15174
19	2004-12-31 19:00:00	15261
20	2004-12-31 20:00:00	14774

Showing 1 to 20 of 121,273 entries, 2 total columns

2. Wyznaczenie podstawowych parametrów opisowych

1. Liczebność próby (ilość pomiarów)

```
# 1. Liczebność próby
n_AEP     <- length(dane$AEP_MW)
```

```
> n_AEP     <- length(dane$AEP_MW)
> n_AEP
[1] 121273
```

2. Suma wszystkich pomiarów (łączna ilosc zuzytej energii)

```
> # 2. Suma wszystkich pomiarów
> sum_AEP   <- sum(dane$AEP_MW, na.rm = TRUE)
> sum_AEP
[1] 1879672527
>
```

3. Średnia arytmetyczna (średnia wartości)

```
> mean_AEP  <- mean(dane$AEP_MW, na.rm = TRUE)
> mean_AEP
[1] 15499.51
>
```

4. Mediana (wartość środkowa)

```
> median_AEP<- median(dane$AEP_MW, na.rm = TRUE)
> median_AEP
[1] 15310
>
```

5. Dominanta / moda (najczęściej występująca wartość)
funkcja mfv() z pakietu modeest

```
> mode_AEP  <- mfv(dane$AEP_MW, na_rm = TRUE)
> mode_AEP
[1] 14941 15399
>
```

Wynik pokazuje, że w kolumnie `AEP_MW` dwie wartości występują najczęściej: `14941` oraz `15399`. Oznacza to, że zbiór danych jest dwumodalny, czyli ma dwie dominanty.

6. Odchylenie standardowe (rozrzut wokół średniej)

```
> # 6. Odchylenie standardowe (rozrzut wokół średniej)
> sd_AEP    <- sd(dane$AEP_MW, na.rm = TRUE)
> sd_AEP
[1] 2591.399
>
```

7. Wariancja (kwadrat odchylenia standardowego)

```
> # 7. Wariancja (kwadrat odchylenia standardowego)
> var_AEP   <- var(dane$AEP_MW, na.rm = TRUE)
> var_AEP
[1] 6715349
>
```

8. Współczynnik zmienności (CV = Odchylenie standardowe / srednia)

```
> # 8. Współczynnik zmienności (CV = sd / mean)
> cv_AEP    <- sd_AEP / mean_AEP
> cv_AEP
[1] 0.1671923
>
```

9. Minimum (najmniejsza wartość)

```
> # 9. Minimum (najmniejsza wartość)
> min_AEP   <- min(dane$AEP_MW, na.rm = TRUE)
> min_AEP
[1] 9581
>
```

10. Maksimum (największa wartość)

```
> # 10. Maksimum (największa wartość)
> max_AEP   <- max(dane$AEP_MW, na.rm = TRUE)
> max_AEP
[1] 25695
>
```

11. Rozstęp (różnica max – min)

```
> # 11. Rozstęp (różnica max - min)
> range_AEP <- max_AEP - min_AEP
> range_AEP
[1] 16114
>
```

12. Kwartyl 1 (25%), dół rozkładu

```
> # 12. Kwartyl 1 (25%), dół rozkładu
> Q1_AEP    <- quantile(dane$AEP_MW, 0.25, na.rm = TRUE)
> Q1_AEP
  25%
13630
>
```

13. Kwartyl 3 (75%), góra rozkładu

```
> # 13. Kwartyl 3 (75%), góra rozkładu
> Q3_AEP    <- quantile(dane$AEP_MW, 0.75, na.rm = TRUE)
> Q3_AEP
  75%
17200
>
```

14. Odstęp międzykwartyłowy (IQR = Q3 – Q1)

```
> # 14. Odstęp międzykwartylowy (IQR = Q3 - Q1)
> IQR_AEP   <- IQR(dane$AEP_MW, na.rm = TRUE)
> IQR_AEP
[1] 3570
>
```

15. Skośność – asymetria rozkładu

```
> # 15. Skośność (skewness) - asymetria rozkładu
> skew_AEP  <- skewness(dane$AEP_MW, na.rm = TRUE)
> skew_AEP
[1] 0.3789934
>
```

16. Kurtoza – spiczastość rozkładu

```
> # 16. Kurtoza (kurtosis) - spiczastość rozkładu
> kurt_AEP  <- kurtosis(dane$AEP_MW, na.rm = TRUE)
> kurt_AEP
[1] 2.788681
>
```

3. Graficzna reprezentacja danych

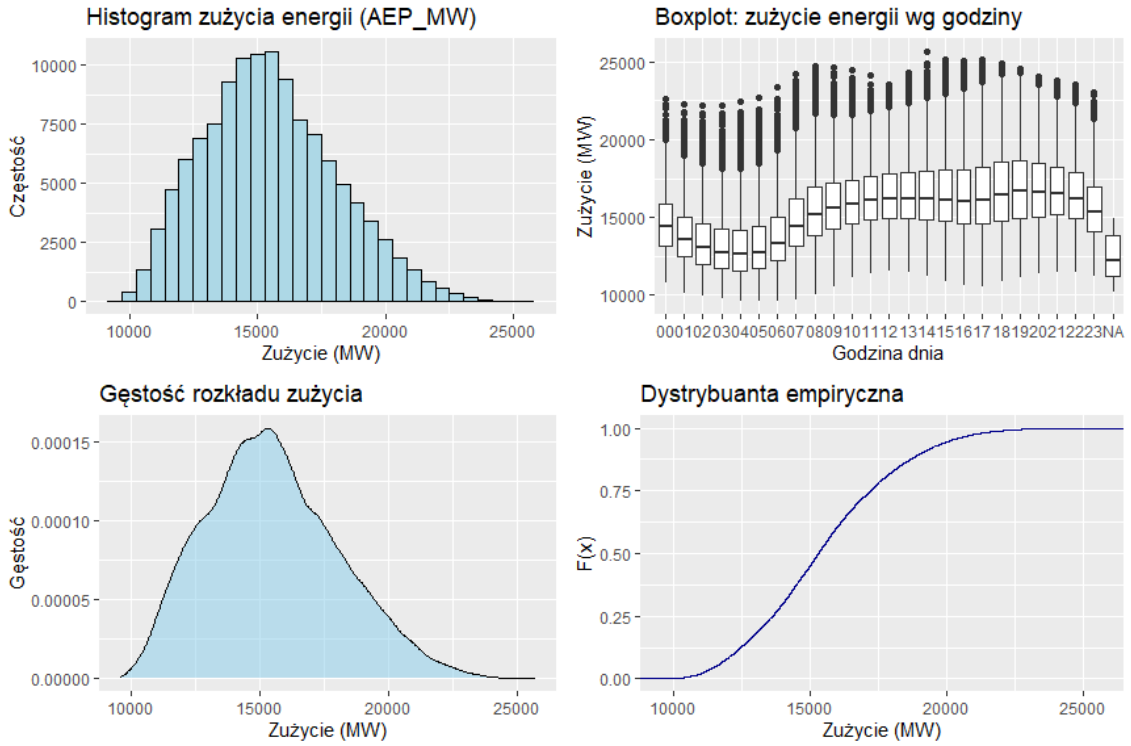

Aby lepiej zrozumieć charakterystykę danych dotyczących godzinowego zużycia energii elektrycznej (AEP_MW), wykonano zestaw czterech wykresów, które w przystępny sposób ukazują rozkład wartości, ich zmienność w czasie oraz występowanie zależności i odchyleń. Wizualizacja danych stanowi ważne uzupełnienie analizy statystycznej – pozwala dostrzec cechy rozkładu, które nie są oczywiste przy samym przeglądzie liczb, oraz wspiera wnioskowanie na temat zachowania badanej zmiennej w czasie.

1. Histogram

```
> # 1. Histogram
> hist = ggplot(dane, aes(x = AEP_MW)) +
+   geom_histogram(bins = 30, fill = "lightblue", color = "black") +
+   labs(title = "Histogram zużycia energii (AEP_MW)", x = "Zużycie (MW)", y = "Częstość")
> View(hist)
```

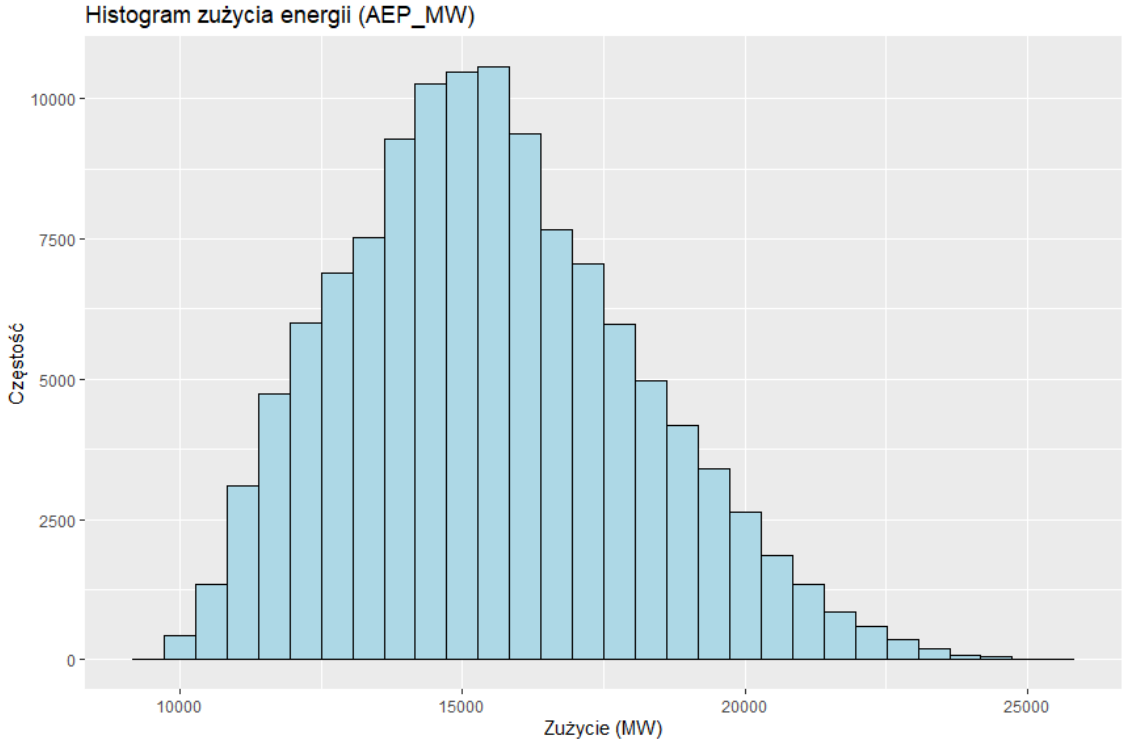

Histogram przedstawia rozkład częstości poszczególnych poziomów zużycia energii. Umożliwia ocenę, czy wartości AEP_MW rozkładają się równomiernie, czy skupiają się w określonym zakresie. W badanym zbiorze danych można zauważyć, że największa liczba obserwacji koncentruje się wokół średnich wartości zużycia, co wskazuje na istnienie dominującego poziomu zapotrzebowania energetycznego. Rozkład ten nie jest idealnie symetryczny, co sugeruje obecność pewnej liczby wyższych wartości odstających.

2.Wykres pudełkowy według godziny

```
> pudelkowy = ggplot(dane, aes(x = godzina_faktor, y = AEP_MW)) +
+   geom_boxplot() +
+   labs(title = "Boxplot: zużycie energii wg godziny", x = "Godzina dnia", y = "Zużycie (MW)")
> pudelkowy
```

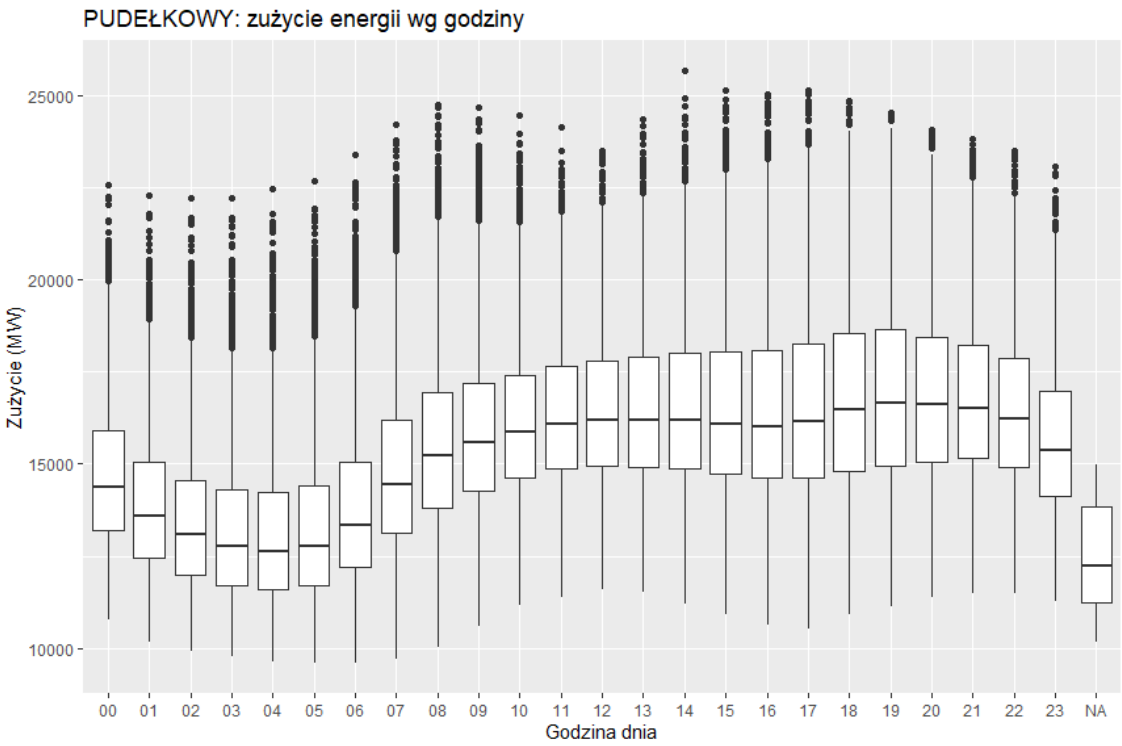

Wykres pudełkowy został użyty do przedstawienia zmienności zużycia energii w zależności od godziny doby. Pozwala on zaobserwować różnice w medianach i rozrzutach zużycia dla każdej z 24 godzin. Wykres ten ujawnia charakterystyczny, dobowy rytm zmian zapotrzebowania na energię – w niektórych porach dnia zużycie wyraźnie wzrasta, a w innych spada. Widoczne są również wartości odstające, które wskazują na nietypowe odchylenia od typowego wzorca, być może związane z ekstremalnymi warunkami pogodowymi lub nietypowym zapotrzebowaniem.

3. Wykres gęstości

```
> gestosc_wykres = ggplot(dane, aes(x = AEP_MW)) +
+   geom_density(fill = "skyblue", alpha = 0.5) +
+   labs(title = "Gęstość rozkładu zużycia", x = "Zużycie (MW)", y = "Gęstość")
> gestosc_wykres
```

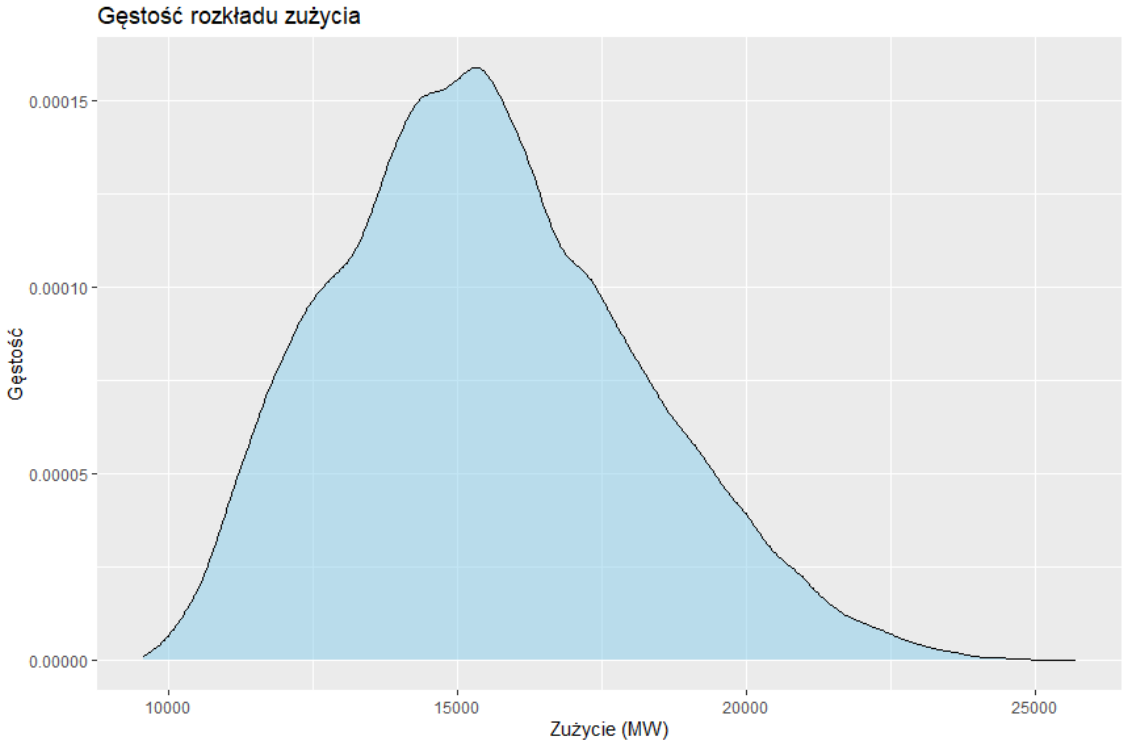

Wykres gęstości służy do estymacji rozkładu prawdopodobieństwa badanej zmiennej – w tym przypadku zużycia energii AEP_MW. W przeciwieństwie do histogramu, wykres ten prezentuje rozkład w formie ciągłej, co pozwala lepiej ocenić jego kształt. W analizowanym zbiorze danych gęstość ma wyraźne maksimum w okolicach wartości średnich, a brzegi rozkładu opadają łagodnie, wskazując na relatywnie umiarkowaną zmienność. Lekka asymetria rozkładu sugeruje, że niektóre wartości znacznie przekraczają przeciętny poziom zużycia.

4. Dystrybuanta empiryczna

```
> # 4. Dystrybuanta empiryczna
> dystrybuanta_wykres = ggplot(dane, aes(x = AEP_MW)) +
+   stat_ecdf(geom = "step", color = "darkblue") +
+   labs(title = "Dystrybuanta empiryczna", x = "Zużycie (MW)", y = "F(x)")
> dystrybuanta_wykres
```

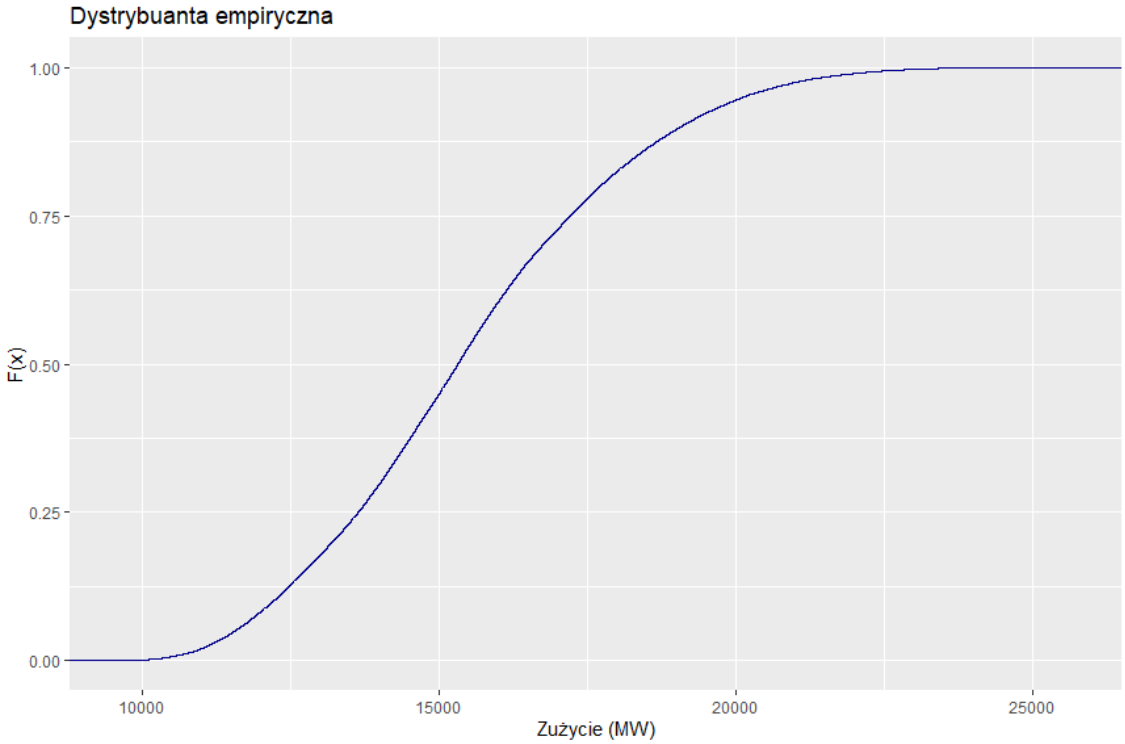

Dystrybuanta empiryczna umożliwia określenie, jaki procent obserwacji nie przekracza określonej wartości. To szczególnie przydatne narzędzie w analizie danych ciągłych, gdy chcemy zrozumieć rozkład skumulowany. W badanym przypadku krzywa ECDF rośnie systematycznie, co oznacza, że dane rozkładają się dość równomiernie w środkowym zakresie wartości, a większość obserwacji mieści się w granicach zbliżonych do mediany. Pozwala to łatwo ocenić, np. ile procent zużycia było poniżej określonego progu, co ma znaczenie w kontekście prognozowania i zarządzania popytem.

4. Weryfikacja hipotez statystycznych

Ostatnim punktem projektu jest weryfikacja hipotez statystycznych. Wykonano dwa testy – test t-Studenta oraz test korelacji Pearsona – dla wybranych danych dotyczących zużycia energii (`AEP_MW`).

4.1 Test t-Studenta

Pierwszy test to test t-Studenta dla jednej próby. Sprawdzamy, czy średnia wartość zużycia energii elektrycznej różni się istotnie od przyjętej wartości referencyjnej 15000 MW.

Hipotezy:

- Hipoteza zerowa : Średnia wartość zużycia energii wynosi 15000 MW ($\mu = 15000$),
- Hipoteza alternatywna : Średnia wartość zużycia energii różni się od 15000 MW ($\mu \neq 15000$).

Przeprowadzamy test t-Studenta przy poziomie ufności 90% ($\alpha = 0.10$):

```
> t.test(dane$AEP_MW, mu = 15000, conf.level = 0.90)

        One Sample t-test

data:  dane$AEP_MW
t = 67.127, df = 121272, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 15000
90 percent confidence interval:
 15487.27 15511.75
sample estimates:
mean of x
 15499.51
```

W analizie przyjęto poziom ufności 90%, co oznacza, że dopuszczalne ryzyko błędu pierwszego rodzaju (odrzucenia prawdziwej hipotezy zerowej) wynosi 10%. Takie założenie pozwala zwiększyć czułość testów statystycznych – dzięki temu możliwe jest wykrycie słabszych zależności lub mniejszych odchyleń od wartości oczekiwanych, które przy bardziej rygorystycznym poziomie 95% mogłyby pozostać niezauważone.

Wartość $p < 0.10$, zatem **odrzucamy hipotezę zerową**. Istnieje istotna, choć słaba ujemna korelacja pomiędzy czasem a zużyciem energii – zużycie w analizowanym okresie nieznacznie maleje.

Statystykę testową t oblicza się ze wzoru:
$\mathbf{t = (\bar{x} - \mu_0) / (s / \sqrt{n})}$
gdzie $\bar{x}$ – średnia z próby, μ_0 – średnia wg H0, s – odchylenie standardowe, n – liczba obserwacji.

4.2 Test korelacji

Drugi test to test korelacji Pearsona. Sprawdzamy, czy zachodzi zależność między czasem (`Datetime`) a zużyciem energii `AEP_MW`. W tym celu konwertujemy zmienną `Datetime` na liczbę sekund od początku pomiarów, aby możliwe było obliczenie współczynnika korelacji.

Hipotezy:

- Hipoteza zerowa: Brak korelacji między zmiennymi ($\rho = 0$),
- Hipoteza alternatywna: Istnieje istotna korelacja między zmiennymi ($\rho \neq 0$).

```
> czas_num <- as.numeric(dane$Datetime)
> cor.test(dane$AEP_MW, czas_num, method = "pearson", conf.level = 0.90)

        Pearson's product-moment correlation

data:  dane$AEP_MW and czas_num
t = -65.487, df = 121257, p-value < 2.2e-16
alternative hypothesis: true correlation is not equal to 0
90 percent confidence interval:
 -0.1893794 -0.1802549
sample estimates:
       cor
-0.1848212
```

Wniosek:
Wartość p jest znacznie mniejsza niż 0.10, co oznacza, że odrzucamy hipotezę zerową i stwierdzamy, że istnieje statystycznie istotna korelacja między czasem a zużyciem energii. Kierunek korelacji jest ujemny, co wskazuje, że w badanym okresie średnie zużycie energii spadało. Choć współczynnik korelacji (-0.18) jest relatywnie niski, efekt jest zauważalny ze względu na dużą liczbę obserwacji.

W celu sprawdzenia liniowej zależności między dwiema zmiennymi wykorzystano współczynnik korelacji Pearsona, obliczany według wzoru:

$$\mathbf{r = \sum(x_i - \bar{x})(y_i - \bar{y}) / \sqrt{[\sum(x_i - \bar{x})^2 * \sum(y_i - \bar{y})^2]}}$$

Wartość r mierzy siłę i kierunek liniowej zależności między zmiennymi. Wartości bliskie 1 lub –1 oznaczają silną zależność, a bliskie 0 – brak istotnej korelacji.

5.Listing komend generujących wyniki

```
# Ustawienie ścieżki roboczej i wczytanie danych
getwd()
setwd("C:/Users/Krzysztof/Desktop/projekt_sts")
dane <- read.csv("AEP_hourly.csv", stringsAsFactors = FALSE)
dane$Datetime <- as.POSIXct(dane$Datetime, format = "%Y-%m-%d %H:%M:%S")
head(dane)

# Instalacja i załadowanie pakietów statystycznych
install.packages(c("modeest", "moments"))
library(modeest)     # moda
library(moments)     # skośność i kurtoza

# Obliczenia statystyk opisowych
n_AEP     <- length(dane$AEP_MW)
sum_AEP   <- sum(dane$AEP_MW, na.rm = TRUE)
mean_AEP  <- mean(dane$AEP_MW, na.rm = TRUE)
median_AEP<- median(dane$AEP_MW, na.rm = TRUE)
mode_AEP  <- mfv(dane$AEP_MW, na_rm = TRUE)
sd_AEP    <- sd(dane$AEP_MW, na.rm = TRUE)
var_AEP   <- var(dane$AEP_MW, na.rm = TRUE)
cv_AEP    <- sd_AEP / mean_AEP
min_AEP   <- min(dane$AEP_MW, na.rm = TRUE)
max_AEP   <- max(dane$AEP_MW, na.rm = TRUE)
range_AEP <- max_AEP - min_AEP
Q1_AEP    <- quantile(dane$AEP_MW, 0.25, na.rm = TRUE)
Q3_AEP    <- quantile(dane$AEP_MW, 0.75, na.rm = TRUE)
IQR_AEP   <- IQR(dane$AEP_MW, na.rm = TRUE)
skew_AEP  <- skewness(dane$AEP_MW, na.rm = TRUE)
kurt_AEP  <- kurtosis(dane$AEP_MW, na.rm = TRUE)

# Instalacja i załadowanie pakietów do wykresów

install.packages(c("ggplot2", "zoo", "forecast"))
library(ggplot2)
library(zoo)
library(forecast)

# Wykresy (ggplot2)

hist <- ggplot(dane, aes(x = AEP_MW)) +
  geom_histogram(bins = 30, fill = "lightblue", color = "black") +
  labs(title = "Histogram zużycia energii (AEP_MW)", x = "Zużycie (MW)", y = "Częstość")

dane$godzina_faktor <- factor(format(dane$Datetime, "%H"))
pudelkowy <- ggplot(dane, aes(x = godzina_faktor, y = AEP_MW)) +
  geom_boxplot() +
   labs(title = "PUDEŁKOWY: zużycie energii wg godziny", x = "Godzina dnia", y = "Zużycie
(MW)")
```

```
gestosc_wykres <- ggplot(dane, aes(x = AEP_MW)) +
  geom_density(fill = "skyblue", alpha = 0.5) +
  labs(title = "Gęstość rozkładu zużycia", x = "Zużycie (MW)", y = "Gęstość")

dystrybuanta_wykres <- ggplot(dane, aes(x = AEP_MW)) +
  stat_ecdf(geom = "step", color = "darkblue") +
  labs(title = "Dystrybuanta empiryczna", x = "Zużycie (MW)", y = "F(x)")

# Połączenie wykresów 2x2
install.packages("gridExtra")
library(gridExtra)
grid.arrange(hist, pudelkowy, gestosc_wykres, dystrybuanta_wykres, ncol = 2)

# Test t-Studenta dla jednej próby
t.test(dane$AEP_MW, mu = 15000, conf.level = 0.90)

# Korelacja Pearsona z czasem
czas_num <- as.numeric(dane$Datetime)
cor.test(dane$AEP_MW, czas_num, method = "pearson", conf.level = 0.90)
```

6. Opis użytych funkcji środowiska R

Poniżej przedstawiono opis najważniejszych funkcji użytych w projekcie, wraz z informacją o ich działaniu oraz pochodzeniu z konkretnych pakietów.

- **`read.csv()`** – wczytuje dane z pliku CSV do ramki danych.
  Pochodzi z pakietu base (domyślnego pakietu R).
- **`as.POSIXct()`** – konwertuje ciąg znaków na obiekt daty i czasu.
  Pakiet base.
- **`length()`** – zwraca liczbę elementów wektora (tu: liczebność próby).
  Pakiet base.
- **`mean()`, `median()`, `min()`, `max()`, `sum()`, `sd()`, `var()`** – funkcje statystyczne obliczające odpowiednio: średnią, medianę, minimum, maksimum, sumę, odchylenie standardowe i wariancję.
  Pakiet base.
- **`quantile()`** – oblicza kwartyle i inne wartości pozycyjne.
  Pakiet base.
- **`IQR()`** – oblicza odstęp międzykwartylowy (Q3 – Q1).
  Pakiet base.
- **`skewness()`** – oblicza skośność rozkładu.
  Pochodzi z pakietu `moments`.
- **`kurtosis()`** – oblicza kurtozę (spiczastość) rozkładu.
  Pakiet `moments`.

- **`mfv()`** – oblicza modę (najczęściej występującą wartość).
  Pakiet `modeest`.
- **`ggplot()`**, **`geom_histogram()`**, **`geom_boxplot()`**, **`geom_density()`**, **`stat_ecdf()`**, **`labs()`** – funkcje do tworzenia wykresów z pakietu `ggplot2`.
  Pakiet `ggplot2`.
- **`grid.arrange()`** – pozwala wyświetlić kilka wykresów obok siebie.
  Pakiet `gridExtra`.
- **`t.test()`** – przeprowadza test t-Studenta dla jednej lub dwóch prób.
  Pakiet base.
- **`cor.test()`** – przeprowadza test korelacji (Pearsona, Spearmana lub Kendalla).
  Pakiet base.
- **`as.numeric()`** – konwertuje obiekty (np. daty) na typ numeryczny.
  Pakiet base.